

# ガウス過程回帰と SHAP を用いた説明可能な AI に基づく 所要調整力決定手法

学生員 西田 啓人<sup>\*a)</sup>      正 員 重信 颯人<sup>\*</sup>      正 員 高橋 明子<sup>\*</sup>  
上級会員 伊藤 雅一<sup>\*</sup>      フェロー 田岡 久雄<sup>\*\*</sup>      上級会員 金尾 則一<sup>\*\*\*</sup>  
正 員 杉本 仁志<sup>\*\*\*</sup>

# Determination Method of Optimal Reserve Margin based on Explainable AI using Gaussian Process Regression Model and SHAP

Keito Nishida<sup>\*a)</sup>, Student Member, Ryuto Shigenobu<sup>\*</sup>, Member, Akiko Takahashi<sup>\*</sup>, Member,  
Masakazu Ito<sup>\*</sup>, Senior Member, Hisao Taoka<sup>\*\*</sup>, Fellow, Norikazu Kanao<sup>\*\*\*</sup>, Senior Member,  
Hitoshi Sugimoto<sup>\*\*\*</sup>, Member

(2023 年 12 月 26 日受付, 2024 年 10 月 16 日再受付)

Electric power systems with increasing photovoltaic (PV) systems face concerns regarding degradation in frequency stability due to heightened output forecast errors. As a countermeasure, given the dynamic factors like demand, PV output, and meteorological elements, calculating the optimal reserve margin (ORM) becomes crucial for economic efficiency and resilience reinforcement. To ensure an efficient ORM, Artificial Intelligence (AI) is one of useful strategies used to analyze the combination of all the elements. However, AI is characterized by a black box problem, and to achieve transparency, AI needs to be transformed into explainable AI. To begin with, this paper analyzed all features importance using SHAP adopting a Gaussian process regression model. Then, relevant explanatory variables were selected to improve the prediction accuracy of the ORM. Finally, to verify the effectiveness, this paper planned day-ahead scheduling while securing the ORM determined by the proposed method. It executed detailed demand/supply and system frequency simulations as an operation. The proposed method decreased the risk posed by PV output forecast errors and shortage of reserve margin. Also, the maximum PV capacity increased from 96.2% to 166.2% while maintaining frequency stability.

キーワード：説明可能な AI (XAI)、SHAP、所要調整力、ガウス過程回帰、PV 導入可能量、周波数安定性

**Keywords :** Explainable AI, SHAP, optimal reserve margin, gaussian process regression, maximum PV capacity, frequency stability

a) Correspondence to: Keito Nishida.

E-mail: [nkd23006@g.u-fukui.ac.jp](mailto:nkd23006@g.u-fukui.ac.jp)

\* 福井大学

〒910-8507 福井県福井市文京 3-9-1

University of Fukui

3-9-1, Bunkyo, Fukui 910-8507, Japan

大和大学

〒564-0082 大阪府吹田市片山町 2-5-1

Yamato University

2-5-1, Katayama-chou, Osaka 564-0082, Japan

\*\*\* 北陸電力（株）新価値創造研究所

〒930-0848 富山県富山市久方町 2-54

Innovation Laboratory, Hokuriku Electric Power Company

2-54, Hisakata-cho, Toyama 930-0848, Japan

1. はじめに

太陽光発電（PV：Photovoltaic Power Generation）の出力は不確実性が高く、様々な周期の変動を含んでいる。それに対し電力系統側では、電力需給バランスの維持のために、前日段階で同期発電機（SG：Synchronous Generator）の発電余裕（調整力）を確保しつつ、最適な出力を計画（UC：Unit Commitment）する必要がある。この UC を基にした当日運用では、変動周期に応じて負荷周波数制御や経済負荷配分制御を行うことで、予測誤差など様々な変動に対応可能である<sup>(1)</sup>。このような系統計画・運用が行われる

中で, PV の主力化が進むと, 不確実性が増大する一方, SG 稼働台数は減少すると考えられる<sup>(2)</sup>。これにより, PV 出力予測誤差に対応可能な二次調整力不足による周波数安定性低下が懸念される。安定性維持のために, 系統側からのアプローチとして調整力の所要量算出・確保, PV 側からのアプローチとして予測精度向上が必要となる。

系統側では, PV 導入量増加に伴い, 周波数安定性や系統レジリエンスの観点から, 調整力の増強が提言されているが, 経済性・環境性は低下することも同時に報告されている<sup>(3)・(4)</sup>。そのため, 両者のトレードオフ関係を鑑みると, 一概に, 調整力増強が最良の方法であるとは限らない。そこでこれまでに, 所要調整力決定のために, ロバスト性解析や確率的解析, クラスタリング技術が用いられ, 効率的な確保に向けた研究報告がある。例えば, Costilla-Enriquez らは, 予測 PV 出力の過去データと生起確率を用いて, 全シナリオの内 10% の最悪ケースの平均値と全シナリオの平均値との差分を所要調整力とするロバスト的手法と, 累積分布関数と信頼区間から所要調整力を決定する確率的手法を提案した<sup>(5)</sup>。Chen は, 所要調整力の過去データを大・中・小にクラスタリングすることで, 季節と時刻に応じた所要調整力曲線を定義した<sup>(6)</sup>。また Knorr らは, 調整力の効率的確保のために, PV や需要の予測誤差分布を, 対数正規分布に従う標準偏差を用いた正規分布でモデル化した<sup>(7)</sup>。これらの報告は, 系統解析を行うことで得た過去データを使った手法であり, 予測誤差と調整力の親和性は高い。これまでの統計的な手法に加えて, 所要調整力に影響を与える雲や風速などの気象変化も考慮する必要がある, 様々な要素に対して気象解析を行うためには, AI の活用が期待される。

PV 側からのアプローチも, AI を活用した研究が進んでいる。PV 出力予測手法において, Zhen らは, 畳み込みニューラルネットワーク (CNN : Convolutional Neural Network) と長短期記憶ネットワーク (LSTM : Long Short-Term Memory) に基づき, 画像データを処理し, 雲の動きを考慮する手法を提案した<sup>(8)</sup>。また Wang らは, 過去の PV 実測値を出力レベルでクラスタリングすることで, 実運用断面での出力パターンを識別できる分類モデルを構築し, それと LSTM を組み合わせることで, 時系列特性を考慮した手法を提案した<sup>(9)</sup>。さらに Sharadga らは, 通常の LSTM が時系列の古い順に学習をするのに対し, 時系列の新しい順にも学習を行う双方向 LSTM を用いた PV 出力予測手法を提案した<sup>(10)</sup>。その他にも, Wang らは, 多目的最適化アルゴリズムと人工ニューラルネットワークを組み合わせた手法<sup>(11)</sup>, Zang らは, MAE や Huber 損失などを含んだ 8 つの損失関数の下で, 全結合層や畳み込み層が更新される新たな CNN を提案した<sup>(12)</sup>。Lai らは, 日射量予測のためのクラスタリング手法を構築する際に, 各特徴量の重みを時間毎に計算できるモデルを構築した<sup>(13)</sup>。しかし, いかなる手法でも予測誤差を排除することはできず, 予測外れがどの程度<sup>(14)・(16)</sup>であるかの解析やそれに対応可能な AI が

必要となる。これは, 所要調整力の推定が可能なモデルを構築することと同義である。

以上の議論を踏まえて, 所要調整力の算出が可能な AI の構築が期待される。しかし, AI はブラックボックス (BLK-AI : Black-box AI) と言われ, 予測結果までの経緯やどの特徴量が最も影響を与えているかの説明が難しい。そのため, どの特徴量を説明変数とするかが課題である。そこで, 目的変数との線形関係を評価できる相関係数<sup>(17)・(19)</sup>や, 非線形の相関関係も評価可能な最大情報係数 MIC<sup>(20)・(22)</sup>などを用いた特徴量の重要度分析がある。これらの分析では, 一対一問での相関性評価が主であり, 重要度の大小だけでは評価できない特徴量間の組み合わせが BLK-AI に内包されているため, モデルを説明するには課題が残る。ここで, BLK-AI を用いて調整力を推定する場合, 所要量が時間帯や天候など様々な要因で変化することを, 予測結果から解釈・説明することは難しい。そこで, 予測過程や結果を理解できるように, 透明性を確保した説明可能な AI (XAI : eXplainable AI) の活用が重要となる。XAI 構築のためには, 各特徴量が予測に与える影響を可視化できる SHAP (SHAP : SHapley Additive exPlanations) を用いた重要度分析や LIME (Local Interpretable Model-agnostic Explanations) を用いた手法が提案されている。SHAP に関する先行研究では, Liu らは, 周波数安定性の予測に対する特徴量の重要度分析で, 送電線の皮相電力や電圧位相角の重要度が高い一方, 発電機の有効電力は重要度が低いと報告した<sup>(23)</sup>。また Zhang らは, IEEE 39bus システムの複数のバスで事故が発生した場合を想定し, 需要制御に対する各バスの電力量や電圧の重要度分析を行った<sup>(24)</sup>。さらに Kruse らは, 周波数安定性の指標として, 周波数変化率, 周波数最大偏差, 周波数偏差の平均二乗値と積算値を定義し, 需要や発電機の計画出力, 風力・PV の予測出力, 時刻, 電気料金など 25 個の特徴量の重要度分析を行った<sup>(25)</sup>。同著者らは, 負荷周波数制御性能に与える重要度も分析し, 需要や PV 出力の予測値に不確実性を模擬することで所要調整力をより効率的に算出できると報告した<sup>(26)</sup>。しかし, 需要や天候の不確実性を同時に扱うことは難しいため, 気象情報を含んだ特徴量の重要度分析を行ったうえで, 所要調整力を効率的に算出できる XAI を構築する必要があるが, そのような報告は, 著者らの知る限りない。

本稿で扱う調整力は, 需要や PV の予測を基にした SG の発電計画の出力を基準とした時に, 実運用断面での需要・PV 出力の誤差 (出力のばらつき) を調整できる最大幅であることから, 学習データのばらつきまで評価可能なガウス過程回帰 (GPR : Gaussian Process Regression) を適用し, 所要調整力の推定精度向上に寄与する特徴量を SHAP による重要度分析で明らかにすることで, それを基にした所要調整力決定 XAI (ORM-XGPR : Optimal Reserve Margin by eXplainable GPR) を提案する。これまでに, 需要や PV 出力に対して一定割合の調整力を確保する検討がなされていたが<sup>(3)</sup>, 提案手法では, 他にどの気象要素が影響を及ぼし

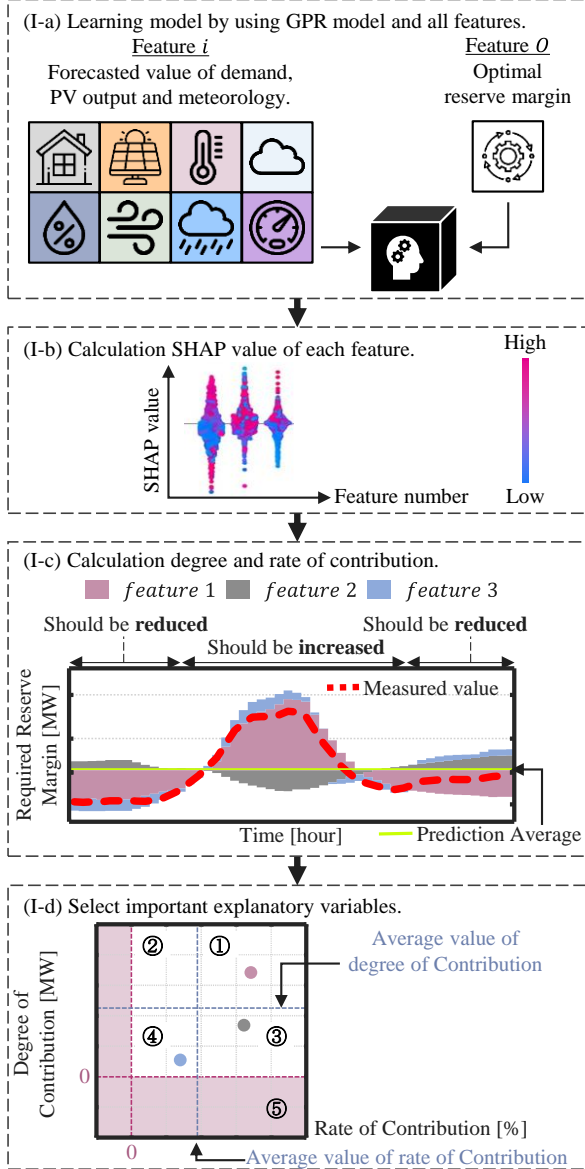
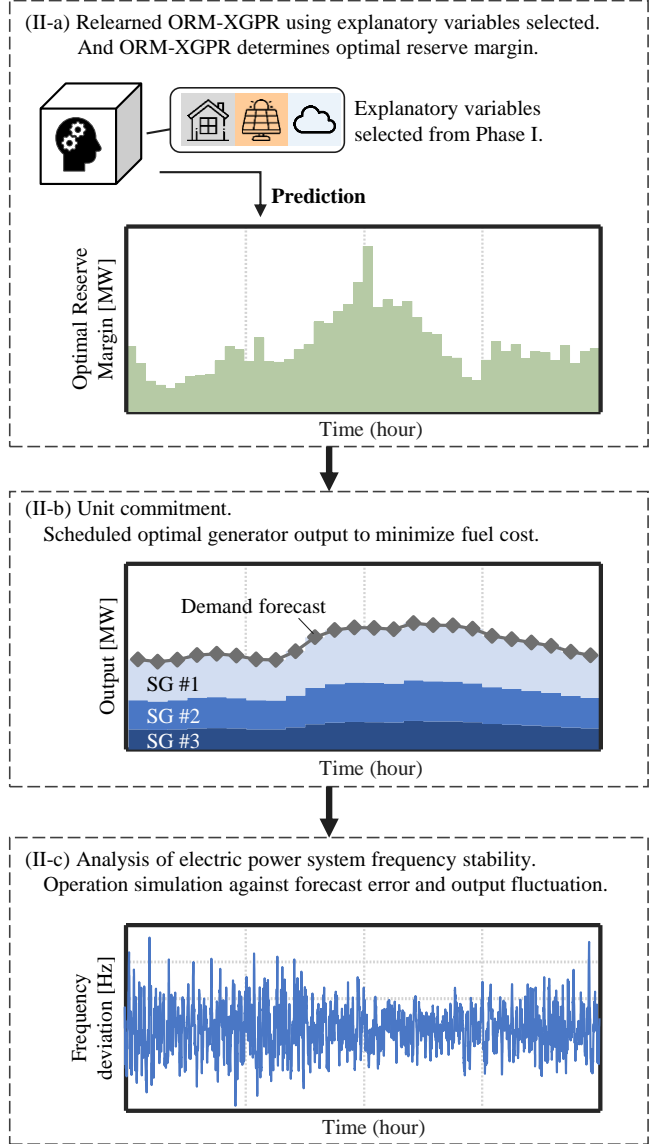
**Phase I****Feature Importance Analysis.****Phase II****Analysis stability by combined between the unit commitment considering the reserve power and operation on the day.**

Fig. 1. Flow chart of ORM-XGPR.

ているかの理解に繋がり、より効率的な調整力確保を目的としている。なお、本稿では上げ・下げ両方の二次調整力を確保するが、解析対象は上げ方向のみとする。これは、優先給電ルールにより下げ調整力が確保され、市場で調達する必要性が低いと整理されているためである<sup>(27)</sup>。手順として、第一に、需要・PV・気象に関する特徴量に対して SHAP による重要度分析を行う（分析手順については次章）。第二に、重要度が高い特徴量を選定し、再度学習することで、効率的な調整力確保のための ORM-XGPR を構築する。第三に、ORM-XGPR と解析対象日の前日予測値を用いて、所要調整力を決定し、同時同量および経済的な運用のための UC 立案を行う。最後に、所要調整力が周波数安定性に与える影響を分析するために、当日運用を模擬した需給周波数シミュレーションを行う。評価として、周波数安定性維持効果、PV 導入可能量増加効果および経済性の

観点から提案手法の有効性を示す。さらに、PV 側の出力予測誤差の増大と系統側の調整力不足、2 つの異なる要因が互いに影響し合うことによる総合的なリスク増大を、提案手法により緩和できることも示す。

## 2. 所要調整力決定 XAI (ORM-XGPR : Optimal Reserve Margin eXplainable GPR)

ORM-XGPR の概略を Fig. 1 に示す。この手法は、2 つのフェーズに大別される。フェーズ I では、重要度分析による特徴量選定を行うために、2.1 節で説明する全特徴量を用いて学習を行い、基準モデルを作成する。ここで、調整力が予測誤差や出力変動に対応する発電余裕であることから、不確実性を含むデータのモデリングに適した手法である GPR を採用する。GPR は、予測値とその分散を評価・算出できる手法である。次に、基準モデルに対して SHAP を

適用することで、予測結果はどの特徴量による影響が大きいかを説明可能な形とする。ここで用いる SHAP は、協力ゲーム理論における各プレイヤーの貢献度を定量的に評価するシャープレイ値 (SHAP 値) を AI 分野に適用し、各特徴量による影響を定量的に評価可能とした手法である。さらに、予測結果と真値を用いて、予測精度向上に寄与するかの絶対量・割合を貢献度、貢献率として分析することで、特徴量の選定を行う。フェーズ II では、選定された特徴量を用いて ORM-XGPR を構築する。次に、本手法適用により算出される所要調整力を確保しつつ、燃料費を最小化するように UC を立案する。最後に、当日運用において秒単位で変動する需要や PV 出力に対する周波数安定性を解析するために、需給周波数シミュレーションを行う。

フェーズ I における重要度分析方法として、SHAP 活用以外に、相関係数や MIC を用いる方法が考えられる。そこで、2.1 節に示す説明変数と所要調整力の相関係数および MIC を Fig. 2 に、日射量に対する予測 PV 出力および所要調整力の散布図を Fig. 3 に、予測誤差に対する所要調整力の散布図を Fig. 4 にそれぞれ示す。Fig. 2 では、予測 PV 出力を除いて、両手法にて高い値を示している変数はない。Fig. 3 では、予測 PV 出力が日射量と線形関係にあるのに対し、所要調整力は線形関係・非線形関係にないことが分かる。また Fig. 4 より、所要調整力と予測誤差には強い相関性が確認できる。しかし、予測誤差の予測は非常に難しいため、予測誤差に影響を与える可能性のある雲や風速などの変数の影響を分析し、AI モデルを構築することが望ましい。そのうえで、AI は解釈可能性・説明可能性を向上させる必要があり<sup>(28)</sup>、本稿では次のように整理する。

解釈可能性は、目的変数が各説明変数とどのような関係があるかを意味し、説明可能性は、モデルの内部の動作プロセスを理解することに関連している。解釈可能性に関しては、相関係数や MIC により解釈できる部分もあるが、AI は深層構造を持ち、入出力関係が複雑になるため、説明可能性の向上は期待できない。そこで本稿では、SHAP 値を以下のように用いて、両可能性を向上させる。まず、SHAP 値を Fig. 1 (I-b) のような beeswarm plot で表現することで、解釈可能性を向上させる。この図は、各説明変数の値の大きさは点の色 (色が赤いほど、その説明変数の値が大きいことを意味する)、モデルの予測結果 (本稿では所要調整力) の増加/削減に寄与した頻度はふくらみ、寄与する大きさは SHAP 値で表現している。また、時系列で示した Fig. 1 (I-c) より、各説明変数の入力からモデル予測結果までの詳細を解析することで、説明可能性を向上させる。

〈2・1〉 データセット UC の時間粒度が 30 分であることから、各特徴量は 30 分値時系列データとする。分析する特徴量は 1 つの目的変数と複数の説明変数で構成されており、それぞれを特徴量  $O$  と複数の特徴量  $i$  とする。特徴量  $O$  は所要調整力、特徴量  $i$  は気象要素・需要・PV 出力のそれぞれの予測値とする。気象予測値は、取得可能なデータである気象庁発行のメソ数値予報モデル (MSM : Meso Scale

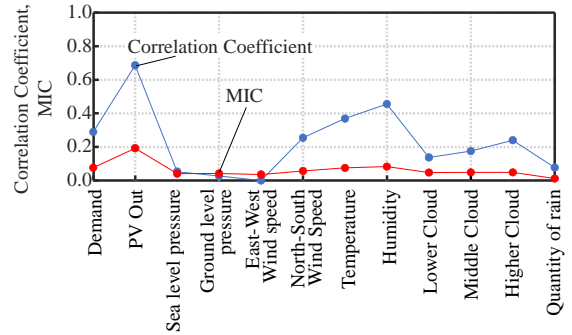


Fig. 2. Correlation coefficient and MIC.

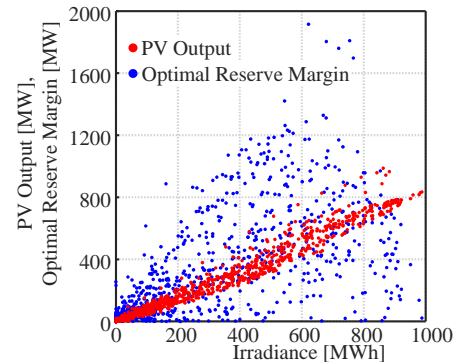


Fig. 3. Irradiance and PV Output, Optimal Reserve Margin.




Fig. 4. Forecast Error and Optimal Reserve Margin.

Model) を参考に、海面気圧、地上気圧、東西風速、南北風速、気温、相対湿度、下層雲量、中層雲量、上層雲量、降水量とする。なお、MSM で利用する格子点は、北陸電力管内における PV300 計測地点とし、全格子点の平均値を気象予測値とする。各 MSM データは 1 時間値であるため、線形補間により 30 分値に換算する。需要予測値は、北陸電力管内の需要実績値の 30 分平均値とする。PV 予測値は、MSM の日射量予測値から換算する。また、所要調整力の時系列データは公表されていないため、電気学会提供の計画から運用までの一連の流れを模擬できる電力需給・周波数シミュレーションの標準解析モデル (AGC30 モデル)<sup>(29)</sup> を用いて系統解析を行った結果から、各 UC 時刻断面での所要調整力を (1) 式で算出する。所要調整力は、各時刻断面の対象区間の内、SG の運用時出力と UC 出力の偏差の最大値、すなわち、その時刻断面で最も使用された調整力



と定義する。

$$P_{t_0}^{RES} = \max_{t=t_0}^{t_0+1800} \sum_g (P_{t,g}^{OPE} - P_{t,g}^{UC}) \dots\dots\dots (1)$$

ここで、 $t_0$  はデータセットの 30 分断面の初期時刻 [sec] ( $t_0 = 0, 1800, \dots$ )、 $g$  は SG 番号 ( $g = 1, \dots, NG$ )、 $P_{t_0}^{RES}$  は各時刻断面の所要調整力 [MW]、 $P_{t,g}^{OPE}$  は AGC30 モデルを用いて得られた出力 [MW]、 $P_{t,g}^{UC}$  は UC 出力 [MW] を表す。

## (2・2) フェーズ I: 重要度分析

(I-a) 基準モデル学習 全特徴量  $i$  に対する特徴量  $O$  を GPR にて学習し、各特徴量  $i$  の入力により所要調整力を予測するモデルを作成する。

(I-b) SHAP 値算出 特徴量  $i$  の SHAP 値  $\phi_{t_0,i}$  [MW] を (2) 式で定義する。これは、特徴量  $i$  を含んだ部分集合と除いた部分集合の偏差に対し、組合せ係数で重み付けた値を合算することで算出する。(2) 式より、組合せ係数は二項係数の逆数であることから、部分集合  $S$  に含まれる特徴量が多いほど、重み付け項が小さくなることを意味する。

$$\phi_{t_0,i} = \sum_{S \subseteq N \setminus i} \frac{|S|!(|N|-|S|-1)!}{|N|!} [GPR(S \cup i, t_0) - GPR(S, t_0)] \dots\dots\dots (2)$$

ここで、 $N$  は全特徴量  $i$  の集合、 $S$  は部分集合、 $GPR$  は基準モデルを表す。 $GPR(S \cup i)$  は特徴量  $i$  を含んだ部分集合  $S \cup i$  に対する  $t_0$  での所要調整力予測値を表す。

(I-c) SHAP 値を考慮した貢献度・貢献率算出 Fig. 5 に、モデル予測平均値 (緑線)、平均値に特徴量  $i$  の SHAP 値を加算した予測結果を積み上げた値、所要調整力の真値 (赤破線) の一例を示す。平均値よりも上に位置する特徴量は、調整力を上げるように働き、下に位置する特徴量は下げるように働くことを意味する。ここで、外部要因や未観測の変数は考慮せず、入力されたデータのみを用いて、全変数を足し合わせると真値と同値になるように SHAP 値が計算され、この特性を加法性という。この加法性により SHAP 値に分解できる。またこの日は、対照的な特徴量 2 と 5 に着目すると、特徴量 2 はどの時間帯においても予測結果を真値へと近づけるように作用していることが確認できる (予測精度向上)。一方、特徴量 5 は、日中の予測結果を真値から遠ざけるように作用していることが分かる (予測精度を下げる原因)。そこで、(3)、(4) で貢献度、(5)、(6) で貢献率を算出する。

$$DC_i = \sum_{t_0} MAG_{t_0,i} \dots\dots\dots (3)$$

$$MAG_{t_0,i} = \begin{cases} +|\phi_{t_0,i}|, \text{予測精度向上} \\ -|\phi_{t_0,i}|, \text{予測精度悪化} \end{cases} \dots\dots\dots (4)$$

$$RC_i = \frac{\sum_{t_0} COND_{t_0,i}}{n(t_0)} \times 100 \dots\dots\dots (5)$$

$$COND_{t_0,i} = \begin{cases} 1, \text{予測精度向上} \\ -1, \text{予測精度悪化} \end{cases} \dots\dots\dots (6)$$

ここで、 $DC_i$  は特徴量  $i$  の貢献度 [MW]、 $RC_i$  は特




Fig. 5. Example of SHAP value for each feature.

徴量  $i$  の貢献率 [%]、 $n(t_0)$  はデータセットの総時刻数を表す。

(I-d) 特徴量選定 Fig. 1 のフェーズ I の (I-d) に、貢献度・貢献率を基にした重要度の分析方法を示す。横軸は貢献率、縦軸は貢献度とし、それぞれの平均値を青点線、0 を紫点線で示す。これより、貢献率・貢献度が共に平均値よりも高いエリア①、貢献度のみ平均値より高いエリア②、貢献率のみ平均値より高いエリア③、貢献率・貢献度が共に平均値よりも低いエリア④、貢献度もしくは貢献率、またはその両方が負であるエリア⑤に分類する。エリア①は貢献度・貢献率が共に高いため、重要度が高い。エリア②は高い貢献度だが、貢献率は低いため、予測精度向上・悪化どちらに影響するかが時間帯で異なり、重要度の不確実性が高い。そのため、時間帯に応じて選択判断をする必要がある。エリア③は低い貢献度だが、貢献率が高いため、基本的に重要であると判断できる。エリア④は、貢献度・貢献率が共に低いため、重要度は低い。また、エリア⑤は、貢献率もしくは貢献度が負であるため、重要度は低い。このルールに従い、エリア①に位置する特徴量のみを説明変数とする ORM-XGPR (①)、エリア①③に位置する特徴量を説明変数とする ORM-XGPR (①・③) を設定し、フェーズ II に進む。

## (2・3) フェーズ II: ORM-XGPR の構築・適用による所要調整力決定および周波数安定性解析

(II-a) ORM-XGPR の学習と利用 重要度分析を基に選定した説明変数を用いて、GPR モデルで再度学習する。また、運用日前日の 30 分値データを入力することで、所要調整力とその分散を (7) 式で算出する。

$$[ORM, Var]_{t_{uc}} = XGPR(\mathbf{t}_{t_{uc}}^{XAI}) \dots\dots\dots (7)$$

ここで、 $t_{uc}$  は UC 時刻断面の初期時刻 [hour] ( $t_{uc} = 0, 0.5, 1, \dots$ )、 $XGPR$  は選定された説明変数を用いて学習した説明可能な GPR モデル、 $ORM_{t_{uc}}, Var_{t_{uc}}$  は GPR モデルで出力される所要調整力とその分散、 $\mathbf{t}_{t_{uc}}^{XAI}$  は選定された説明変数群を表す。

(II-b) UC 立案 所要調整力は、系統安定性・経済性・環境性を鑑みて、(8) 式の左辺のように、平均値 +  $2\sigma$  とする。 $1\sigma$  の場合は、系統安定性低下の可能性がある一方で、 $3\sigma$  の場合は向上が期待される。しかし、稼働すべき火力発電機の台数が増加するため、経済性・環境性は

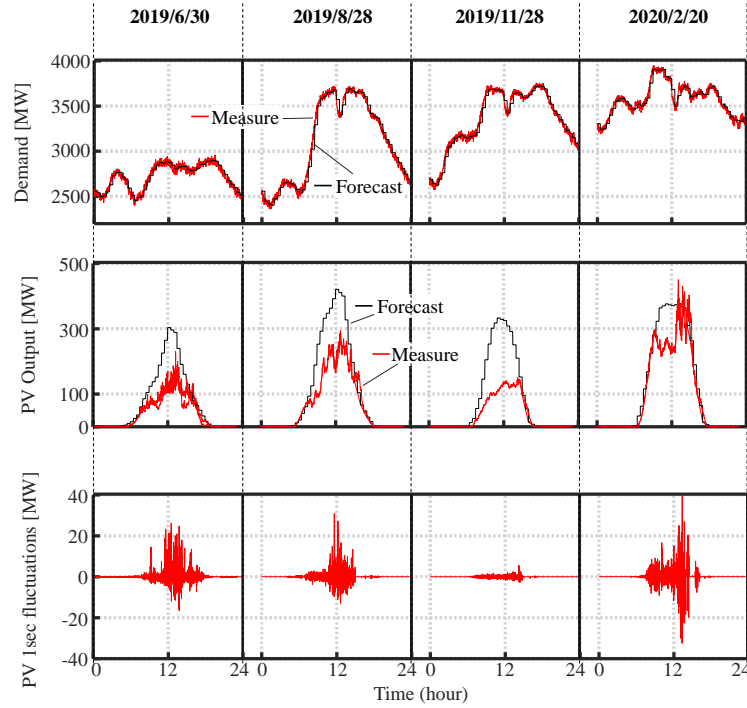


Fig. 6. Profile of demand (Upper), PV output (Middle), PV 1 second fluctuations (Lower).

悪化する可能性がある。また、同制約を満たしつつ、系統全体の燃料費を (9), (10) 式に基づいて最小化するように各 SG の最適出力を計画する。本稿で対象とする UC は、メリットオーダーに基づき、他にも需給バランス制約、出力上下限制約、出力変化速度制約、起動停止維持時間制約を設定する。

(所要調整力確保制約)

$$ORM_{t_{UC}} + 2 \cdot \sqrt{\text{Var}_{t_{UC}}} \leq RM_{t_{UC}} \dots \dots \dots (8)$$

(目的関数)

$$\min\{\sum_{t_{UC} \in 48} \sum_{g \in NG} FC_g(p_{t_{UC},g})\} \dots \dots \dots (9)$$

$$FC_g(p_{t_{UC},g}) = a_g + b_g \cdot p_{t_{UC},g} + c_g \cdot (p_{t_{UC},g})^2 \dots \dots \dots (10)$$

ここで、 $p_{t_{UC},g}$  は UC 出力 [MW] を表す。また、 $RM_{t_{UC}}$  は確保調整力 [MW] を表し、稼働 SG の定格出力と UC 出力の差分の合計値とする。さらに、 $FC_g(p_{t_{UC},g})$  は燃料費、 $a_g, b_g, c_g$  は燃料費特性係数を表す。

(II-c) 周波数安定性解析 秒単位で変化する予測誤差・出力変動に対して、ORM-XGPR で算出された所要調整力が、周波数安定性に貢献するかを解析するために、電力需給・周波数シミュレーションを行う。

### 3. 検証条件

〈3・1〉 条件 学習期間は日射量が多い 6 月 (2019 年 6 月 1 日～29 日)、運用日は 2019 年 6 月 30 日、2019 年 8 月 28 日 (夏季)、2019 年 11 月 28 日 (秋季)、2020 年 2 月 20 日 (冬季) とする。学習期間は、各運用日で変更せず、6 月で固定する。また PV 導入量を、学習期間の最大需要約 4200MW に対する PV 設備容量 [MW] の割合とし、PV 導

入量 100% の時は、最大需要と同値の PV 導入量を意味する。基準 PV 導入量は、北陸エリアの導入量 26.2% (1100MW) <sup>(30)</sup> とする。さらに、所要調整力算出のために ORM-XGPR の学習で用いる予測 PV 出力は、PV 導入量 130% (基準 PV 導入量の約 5 倍) を想定する。これは、PV 発電効率を考慮しても最大需要を賄える量である。

Fig. 6 に運用日の需要予測値・実測値、基準 PV 導入量における実測 PV 出力 (PV300 の北陸電力管内における全計測地点の平均日射量を変換)・予測 PV 出力 (PV300 の北陸電力管内における全計測地点を格子点とした場合の、MSM の平均日射量予測値を変換)、PV の短周期変動 (1 秒変動値) を示す。2019 年 8 月 28 日は需要のランプ、実測 PV 出力の大外れ、大きな短周期変動が重なる過酷日である。ORM-XGPR で決定される所要調整力は上げ調整力であり、需要や PV 出力の予測誤差が原因で発生する電力供給不足時に活用される。そこで、実測 PV 出力が下振れするこれらの日を対象に、基準 PV 導入量から 10% 刻みでスニープ解析を行う。また、計画および運用は、次のルールに従うこととする。提案手法で算出された所要調整力を確保しつつ、火力発電機の出力を抑制する。その後、調整力を確保できない場合に限り、PV の出力を抑制する。なお、PV 導入量増加によるならし効果の影響は考慮していない。

比較手法として、従来の所要量 (需要の 10%) に、PV 導入量増加への対策として、予測 PV 出力の 25% を加えた量を所要調整力とする DPV 手法 (Demand-PV-method) <sup>(3)</sup> を設定する。また、特徴量の重要度分析を行わず、すべての特徴量を用いて学習する BLK-AI を設定する。BLK-AI と比較して、重要度分析により解釈可能性・説明可能性を向上させた手法が本提案手法 ORM-XGPR である。さらに、エ

リア①の特徴量のみを説明変数とする ORM-XGPR (①) は、選択できる変数の数が ORM-XGPR (①・③) より少ないことに留意されたい。

シミュレーションで用いる SG 構成を Table 1 示す。(10) 式で用いる燃料費特性係数は、算定期間で変動するものであり一意に決めることが出来ない。そのため、実際の SG の特性ではなく、電気学会技術報告 (29) を参考にし、燃種や定格出力の大きさ毎に設定していることに留意されたい。また、起動停止維持時間は 2 時間とした。

〈3・2〉 評価指標 系統のリスクや安定性、PV の導入限界、経済性を評価するために 4 つの指標を設定する。

(指標 I) リスク PV 側の出力予測誤差増大とそれによる系統側の調整力不足、2 つの要因によるリスク評価を行うために、信頼工学における「掛け算型リスク」を用いる。掛け算型は、数学における期待値と同等であり、(11) 式に示すように、ある事象の発生確率 (Prob) とその影響の大きさ (Effect) を掛け合わせることで表現される。

$$RISK = Prob \times Effect \dots\dots\dots (11)$$

ここでは、ある事象を「予測 PV 出力の誤差発生」として、リスクを定義する。発生確率は、実測 PV 出力が予測 PV 出力の 50%未満の場合を大外れと仮定して、(12)、(13) 式で定義する。また、その影響度の大きさとして、予測誤差が所要調整力を上回った場合を危険状態と仮定し、(14)、(15) 式で定義する。さらに、(12)、(14) 式を (11) 式に代入することで、リスク評価を行う。

$$Prob = \frac{\sum I_t^{PV}}{T} \dots\dots\dots (12)$$

$$I_t^{PV} = \begin{cases} 1, & p_t^{PVmeas} < 0.5 \cdot p_t^{PVfore} \\ 0, & p_t^{PVmeas} \geq 0.5 \cdot p_t^{PVfore} \end{cases} \dots\dots\dots (13)$$

$$Effect = \frac{\sum I_t^{EPS}}{T} \dots\dots\dots (14)$$

$$I_t^{EPS} = \begin{cases} 1, & ORM_t + 2 \cdot \sqrt{Var_t} < (p_t^{PVfore} - p_t^{PVmeas}) \\ 0, & ORM_t + 2 \cdot \sqrt{Var_t} \geq (p_t^{PVfore} - p_t^{PVmeas}) \end{cases} \dots\dots\dots (15)$$

ここで、 $t$  は時間 [sec] ( $t = 1, 2, \dots, T$ )、 $T$  は 1 日の秒数 86400 [sec] を表す。 $p_t^{PVfore}$ 、 $p_t^{PVmeas}$  は PV の予測値、実測値 (1 秒値) であり、 $ORM_t$ 、 $Var_t$  は、(7) 式の  $ORM_{tuc}$ 、 $Var_{tuc}$  の 30 分値をそのまま 1 秒値とした値を表す。

(12) ~ (15) 式を用いて算出されるリスクは、数値の大小関係にのみ着目する。例えば、BLK-AI のリスクが 0.06、ORM-XGPR のリスクが 0.02 である場合、ORM-XGPR のほうがリスクを軽減できると評価し、0.06 や 0.02 といった絶対量自体は意味を持たない点に留意されたい。

(指標 II) 安定性 系統安定性の指標として、周波数偏差が  $\pm 0.1\text{Hz}$  を逸脱した確率 (FDP : Frequency Deviation Probability) を (16)、(17) 式で算出する。周波数管理目標値が  $\pm 0.1\text{Hz}$  以内に 95%以上であることから、FDP が 5%以下である場合を周波数安定とする。

Table 1 Electric power system synchronous generators.

SG	Rated Output [MW]	Minimum Output [MW]	$a_g$ [JPY]	$b_g$ [JPY/MW]	$c_g$ [JPY/MW <sup>2</sup> ]	generation unit cost
Oil#1	250	40	316	4.6	0.00105	6.1
Oil#2	250	75	200	5	0.00005	5.8
Oil#3	500	75	200	5	0.00005	5.4
Oil#4	250	35	316	4.6	0.00105	6.1
Coal#1	250	60	40	2	0.0002	2.2
Coal#2	250	60	40	2	0.0002	2.2
Coal#3	500	100	120	1.5	0.00018	1.8
Coal#4	700	140	182	1.3	0.00016	1.7
Coal#5	500	100	120	1.5	0.00018	1.8
Coal#6	700	140	182	1.3	0.00016	1.7
LNG	425	178	120	1.4	0.00166	2.4

$$FDP = \frac{\sum I_t^{FDP}}{T} \times 100 \dots\dots\dots (16)$$

$$I_t^{FDP} = \begin{cases} 1, & |\Delta f_t| > 0.1 \\ 0, & |\Delta f_t| \leq 0.1 \end{cases} \dots\dots\dots (17)$$

ここで、 $\Delta f_t$  は周波数偏差を表す。

(指標 III) 経済性 周波数安定性とトレードオフ関係にある経済性の指標として、燃料費 (FC : Fuel Cost) を (18) 式で算出する。

$$FC_g(p_{t,g}) = a_g + b_g \cdot p_{t,g} + c_g \cdot (p_{t,g})^2 \dots\dots\dots (18)$$

ここで、 $p_{t,g}$  は運用時出力 [MW] を表す。

(指標 IV) PV 導入限界 PV 側の評価指標として、PV 導入可能量 (MPVC : Maximum PV Capacity) は、周波数安定でない PV 導入量の内の最小値から 10%差し引いた値とする。これは、スワイプ解析での PV 導入量刻み幅が 10 [%] であることに起因する。

## 4. 検証結果

〈4・1〉 各説明変数の所要調整力への影響評価 2019 年 6 月 1 日 ~ 29 日を解析した場合の、各説明変数における SHAP 値を Fig. 7 に示す。横軸を説明変数、縦軸を SHAP 値として、各変数の値の大きさは点の色、所要調整力の増加/削減に寄与した頻度はふくらみ、寄与する大きさは SHAP 値で表現した。例えば、需要における赤色は、需要が大きいことを意味する。




Fig. 7. Beeswarm plot of each feature.

需要については、軽負荷時・高負荷時に関わらず、所要調整力の増加および削減の両方に影響を与えた。次に、予測 PV 出力が低い早朝・夜間（青点）には、主に-180 [MW] 程度でふくらみがあることから、この時間帯は所要調整力の削減に寄与する頻度が高いことが分かる。一方で、曇天日などの、予測 PV 出力がゼロではないが、低出力の時（紫点）、快晴日などの予測 PV 出力が高い時（赤点）には、所要調整力の増加に寄与している。また、全特徴量の中で最も SHAP 値の変化幅が広いことから、予測結果に大きく影響していることも確認できる。海面気圧または地上気圧が高い時（赤点）は下降気流が発生し、雲ができにくくなるため、天候の乱れが少ない傾向があり、所要調整力の削減に寄与した。また、海面気圧と地上気圧は、同じような特徴が見られた。風向に関しては、東西風速が強く（赤点）、南北風速が弱い（青点）場合、所要調整力の削減に寄与し、風向が逆転すると増加に寄与した。一方で、気温が低い時（青点）は主に-60 [MW] で、中間的な気温レベル（紫点）では主に-20 [MW] で所要調整力の削減に寄与し、気温が高い時（赤点）は増加の寄与が顕著で、SHAP 値の変化幅も大きくなった。また、湿度が低い乾燥時（青点）には、所要調整力の削減が顕著で、高湿度時（赤点）には微増に寄与した。雲量においては、下層雲量が多い場合（赤点）は、所要調整力の増加・削減の両方に

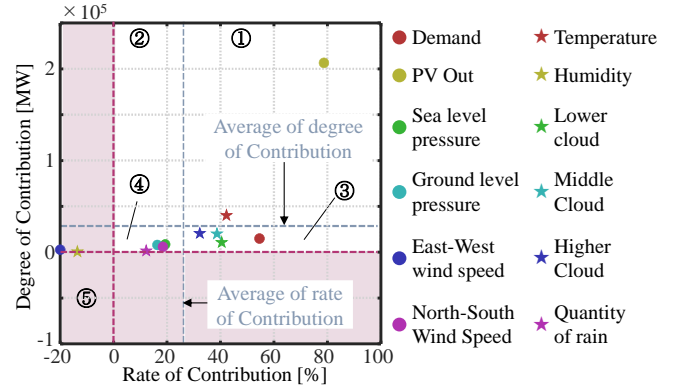


Fig. 8. Degree and Rate of contribution to analyze feature importance.

(Degree Average:  $2.8 \times 10^4$  MW, Rate Average: 26.7 %)

寄与する場合があります。一方で、中層・高層雲量が少ない時（青点）は増加に、多い時（赤点）は削減に寄与した。

〈4・2〉 特徴量重要度分析 横軸を貢献率、縦軸を貢献度として、各特徴量の分析結果を Fig. 8 に示す。これより、全特徴量の平均貢献率は26.7%, 平均貢献度は $2.8 \times 10^4$  MW であった。それに対して、予測 PV 出力、気温は貢献率と貢献度が共に平均値よりも高いことが確認でき、重要

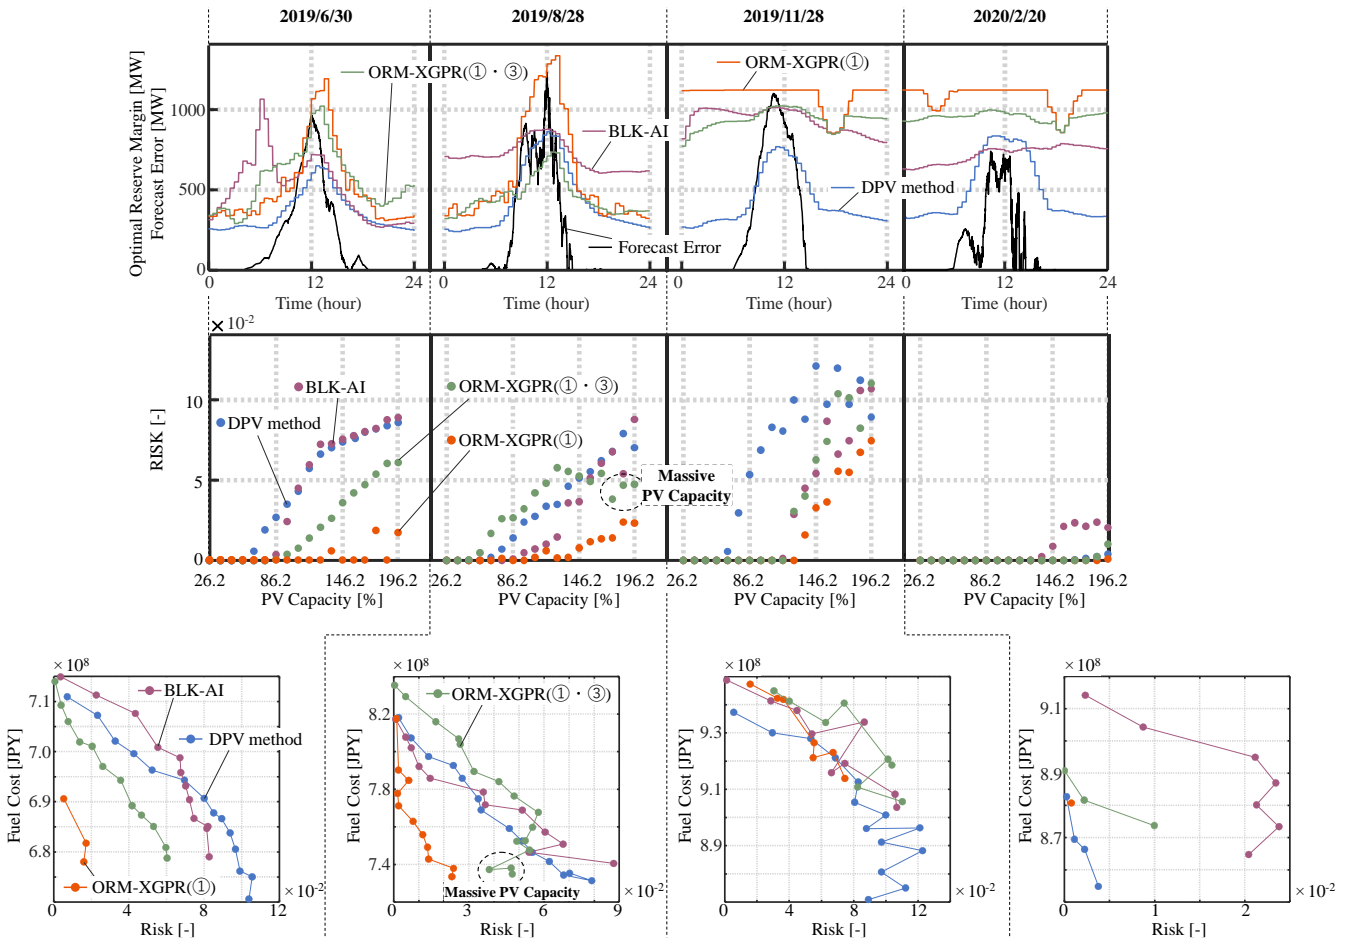


Fig. 9. Optimal Reserve Margin at PV capacity 130% (Upper), Risk as per PV Capacity (Middle), Fuel Cost as per Risk (Lower).



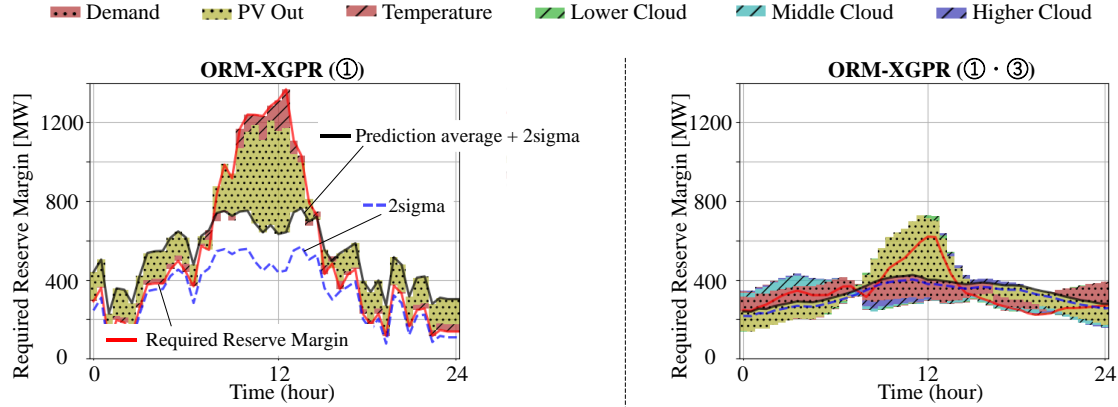


Fig. 10. Time-series SHAP value for each method.

な特徴量と言える。また、予測需要、低・中・高層雲量の貢献率は平均貢献率よりも高いことから、基本的に予測精度向上に寄与するため、重要であると言える。一方、その他の特徴量は平均値よりも低いことから、予測精度を下げる方向に寄与する割合が大きくなり、重要度が低いと言える。これより、ORM-XGPR (1) では、予測 PV 出力、気温を説明変数として選択、ORM-XGPR (1)・(3) では、予測需要、予測 PV 出力、気温、低・中・高層雲量を説明変数として選択することとする。

〈4・3〉 所要調整力・リスク・燃料費から見た提案手法の評価 Fig. 9 の上段には PV 導入量 130%における 1 日の所要調整力と予測 PV 出力の誤差を、中段には PV 導入量に応じたリスクを、下段にはリスクに応じた燃料費を示す。

(Test 1) 2019 年 6 月 30 日 Fig. 9 上段より、ORM-XGPR による所要調整力の形状に関して、DPV 手法適用時の形状と同様に、朝方から昼間にかけて増加、昼間から夕方・夜間にかけて減少となった。絶対量に関しては、より多くの調整力を確保すべきと予測されたことにより、予測誤差を賄えることが分かった。また、中段より、ORM-XGPR 適用時は、DPV 手法よりもリスクを軽減できた。さらに、下段より、同じリスクを考慮する場合、BLK-AI、DPV 手法よりも燃料費を削減できることが分かった。

(Test 2) 2019 年 8 月 28 日 (過酷日) Fig. 9 上段より、(Test 1) と同様に、ORM-XGPR 適用時は、所要調整力の形状は、DPV 手法と概ね一致するが、最大値は異なることが分かった。また、中段より、ORM-XGPR (1) 適用時は、所要調整力が多く見積もられることで、最もリスクを軽減でき、ORM-XGPR (1)・(3) 適用時は、所要調整力が低く見積もられることで、ハイリスクとなった。ここで、どの説明変数が所要調整力の増減に影響したかの説明可能性を明らかにするため、Fig. 10 に、SHAP 値の時系列データと  $2\sigma$  値 (青破線)、モデル平均値 +  $2\sigma$  値 (黒線) を示す。この図は、黒線よりも上に位置する特徴量は、調整力を上げるように働き、下に位置する特徴量は下げるように働くことを意味する。ORM-XGPR (1) 適用時は、日中に、予測 PV 出力が所要調整力の増加に寄与しており、気

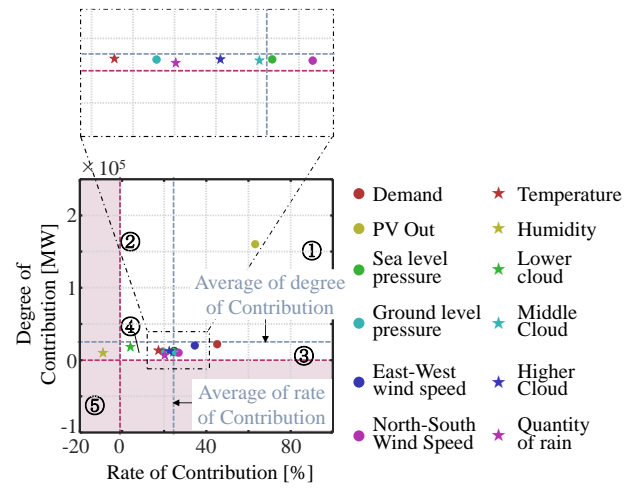


Fig. 11. Degree and Rate of contribution to analyze feature importance on December.

(Degree Average:  $2.6 \times 10^4$  MW, Rate Average: 24.4%)

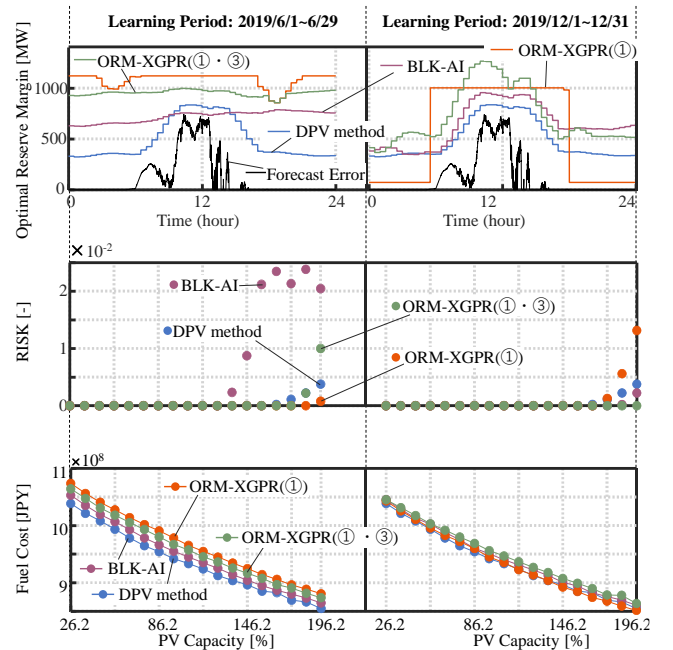


Fig. 12. Optimal Reserve Margin (Upper), Risk (Middle), Fuel Cost (Lower).

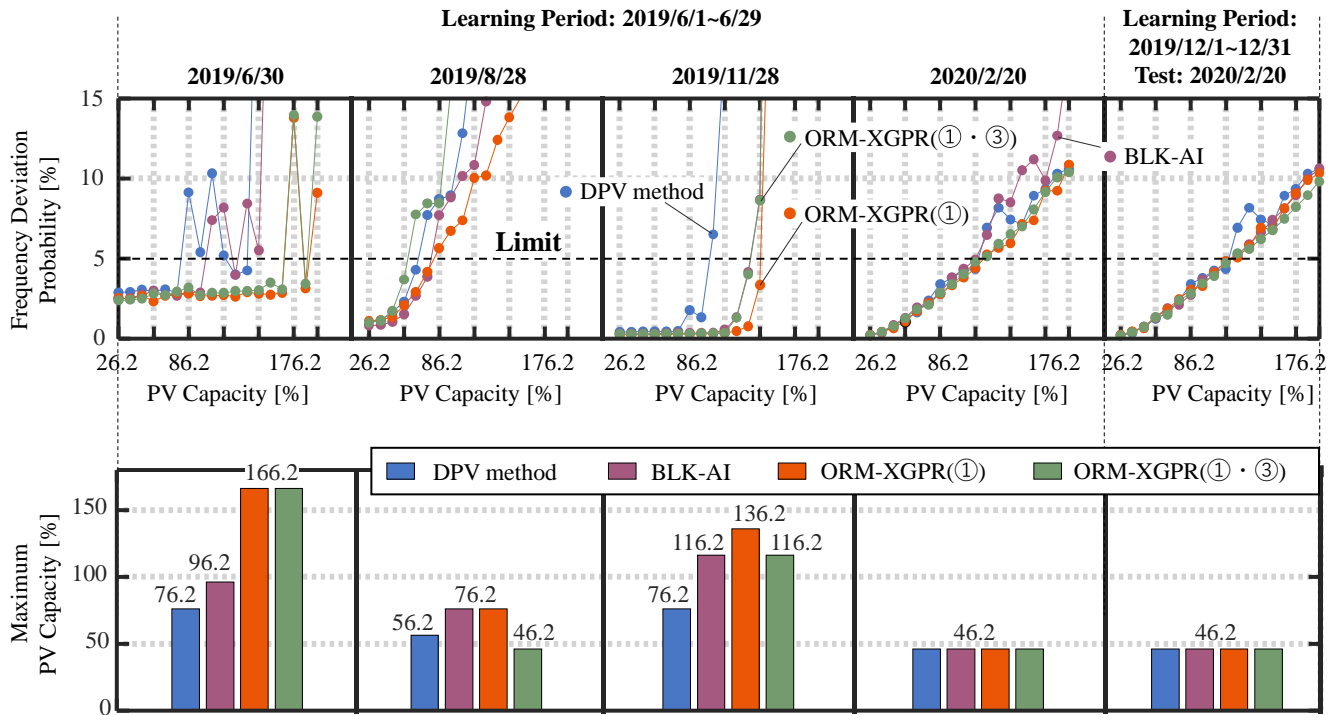


Fig. 13. Frequency Deviation Probability (Upper), Maximum PV capacity (Lower).

温は微増に寄与している。また、ORM-XGPR (①) は説明変数が少ないことに起因して、ORM-XGPR (①・③) に比べて、モデルが単純となるため、予測の不確実性が増加し、日中の $2\sigma$ 値(モデルのばらつき)が大きくなった。結果的に、過酷日でも対応可能な所要調整力を予測した。一方で、本稿では対象としていない予測誤差が小さくなる快晴日や準快晴日では、不要な調整力の確保に繋がる可能性があり、燃料費の増加が懸念される。ORM-XGPR (①・③) 適用時は、予測 PV 出力が日中に所要調整力を増加させているのに対し、雲量や需要は削減に寄与している。また $2\sigma$ 値は小さいため、不確実性が ORM-XGPR (①) よりも小さく、過酷日においては、予測誤差に対応できなかった。しかし、Fig. 9 中段より、PV 導入量 126.2%から、ORM-XGPR (①・③) のリスクが増加しなくなっているのに対し、DPV 手法のリスクは増加し続けている。そのため、Fig. 9 下段より、PV 大量導入時に、ORM-XGPR (①・③) を適用すると、DPV 手法と比べて、燃料費を削減できることが示唆された。以上より、稀に発生する過酷日に対応可能な ORM-XGPR (①) のような不確実性が大きいモデルか、不確実性が小さい ORM-XGPR (①・③) のようなモデルを構築するかを選択が必要となり、それに応じた説明変数の選定が必要である。

(Test3・4) 2019年11月28日、2020年2月20日 学習期間との時間的な距離が遠いこれらの日に、ORM-XGPR を適用すると、時間帯に限らず常に平均的な値を出力した。そこで、冬季始まりの12月のデータを用いて、学習および特徴量重要度分析を行った。Fig. 11 に重要度分析の結果を示す。また、構築した ORM-XGPR を2020年2月20日に適用した場合の結果として、Fig. 12 の上段に PV 導入量

130%における1日の所要調整力と予測 PV 出力の誤差を、中段に PV 導入量に応じたリスクを、下段に燃料費を示す。Fig. 11 より、Fig. 8 と同様に予測 PV 出力は重要な特徴量となった。また、6月の学習と同様に、予測需要は平均貢献率よりも高くなった。一方、6月はエリア③に属していた雲量が、エリア④に移動していることも確認できる。新たに、海面気圧、東西風速、南北風速が基本的に予測精度向上に寄与する特徴量となった。これより、ORM-XGPR (①) では、予測 PV 出力のみを説明変数として選択、ORM-XGPR (①・③) では、予測需要、予測 PV 出力、海面気圧、東西・南北風速を説明変数として選択した。学習期間6月と学習期間12月の結果を比較するために、それぞれを ORM-XGPR6、ORM-XGPR12 と命名する。例えば、学習期間12月でエリア①・③の特徴量を採用する場合は、ORM-XGPR12 (①・③) となる。Fig. 12 上段より、ORM-XGPR12 (①・③) を適用することで、ORM-XGPR6 (①・③) の平均的な値ではなく、DPV 手法適用時の所要調整力の形状と似た予測結果となった。一方、ORM-XGPR12 (①) は、予測 PV 出力のみを説明変数としていることに起因して、所要調整力の時系列の特徴は捉えているが、極端な予測結果となった。また、ORM-XGPR12 (①・③) を ORM-XGPR6 (①・③) と比較すると、中段より、リスクが低減され、下段より、燃料費も削減できたことが分かった。

〈4・4〉 周波数逸脱確率・PV 導入可能量 運用日4日間と、学習期間を12月とした場合の2月20日における周波数逸脱確率、PV 導入可能量を Fig. 13 に示す。

(Test 1) 2019年6月30日 DPV 手法の PV 導入可能量は 76.2%、BLK-AI は 96.2%であったが、ORM-XGPR を適用することで、PV を 166.2%まで導入しても、周波数安




Fig. 14. Frequency deviation at  
(a) PV 176.2%, (b) PV 186.2% and  
(c) the operation duration time of Coal #2 is  
1 hour at PV 176.2%.

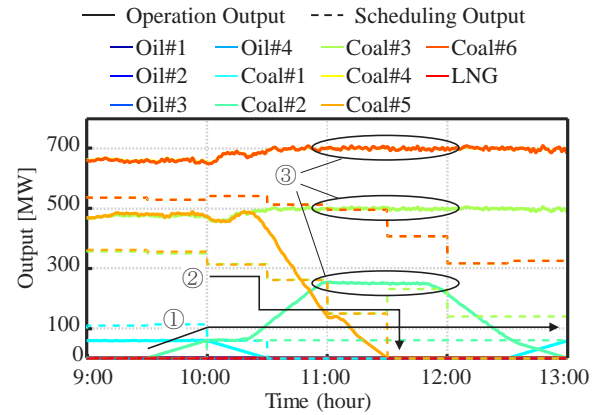
定性が維持されることが明らかになった。

(Test 2) 2019 年 8 月 28 日 ORM-XGPR (①) を適用することで、DPV 手法より 20pts の PV 導入可能量増加効果が確認された。一方、ORM-XGPR (①・③) は、Fig. 10 でも示したように、所要調整力が小さく見積もられているため、PV 導入可能量増加効果は確認できなかった。


(Test 3) 2019 年 11 月 28 日 ORM-XGPR (①・③) を適用することで、DPV 手法より 40pts の PV 導入可能量増加効果が確認された。

(Test 4・5) 2020 年 2 月 20 日 どちらの学習期間においても PV 導入可能量が同等量となった。これは、Fig. 6 より、短周期変動が大きいことが要因の一つとして考えられる。この変動は、本稿で対象とした二次調整力が対応する変動周期よりも短い周期の変動であるため、これらの変動に対する調整力（一次調整力）の所要量の決定についても、今後更なる検討が必要となる。


〈4・5〉 調整力不足による安定性低下事例 Fig. 13 より、2019 年 6 月 30 日に ORM-XGPR (①・③) を適用し、PV 導入量を 176.2%から 186.2%に増加させた時、周波数逸脱確率が低減されていることが分かる。そこで、PV 導入量 176.2%の時の周波数偏差を Fig. 14 に、SG の UC 計画出力を点線、運用時出力を実線で Fig. 15 (a) に示す。Fig. 14 より、周波数偏差が 11:00 以降に大幅に低下している。Fig. 15 (a) の UC 計画出力に着目すると、① Coal#2 が 10:00 に起動し、起動維持時間制約により 2 時間以上最小出力で稼働する計画が立案されている。② 同時に、Coal#5 の出力は他の SG に持ち替える運用となり、11:30 に停止するために、段階的に出力を低下させている。さらに、運用時出力に着目すると、③ 全稼働 SG が調整力を使い切り、定格出力付近で運転している。結果的に、定格出力 500MW の Coal#5 の出力を他の SG の調整力及び定格出力 250MW の Coal#2 での持ち替えでは対応できず、周波数偏差が大きく逸脱した。そこで、これに対して、PV 導入量増加による SG 出力負担の軽減 (考察 1)、起動停止維持時間制約の緩和 (考察 2) による安定性維持効果を示す。Fig. 14 に (b) PV186.2%の場合、(c) PV176.2%導入時に起動維持時間を 1 時間とした場合の周波数偏差、Fig. 15 に各ケースの SG の



(a) Operation duration time of Coal#2 is 2 hours  
at PV 176.2%.



(b) Operation duration time of Coal#2 is 2 hours  
at PV 186.2%.



(c) Operation duration time of Coal#2 is 1 hour  
at PV 176.2%.

Fig. 15. Synchronous generator output during  
unit commitment and operation.

挙動を示す。

(考察 1) PV 導入量増加 Fig. 15 (b) より、PV 導入量 186.2%に増加させることで、PV 出力増加分により、Coal#2 の追加起動や Coal#5 の持ち替えが必要なく、結果的に、柔軟な運用が可能となった。

(考察 2) 起動停止維持時間制約緩和 Fig. 15 (c) より、起動維持時間を 1 時間に変更した場合は、(a) と同様、10:00 に Coal#2 が起動しているが、1 時間後には停止する計画が立案されている。そのため、Coal#5 を停止させる必要はなく、柔軟な運用により周波数安定性が維持された。

## 5. まとめ

PV の更なる導入が必要である一方で、不確実性が高いことから導入量増加に伴う予測誤差増大による周波数安定性低下が懸念されている。課題解決のためには、調整力の所要量を算出し、経済的かつ安定性が維持できる運用を行う必要がある。所要調整力は需要や PV 出力、気象要素など様々な要因で変化するため、調整力不足の運用状況を含んだ過去データを AI で学習することで、効率的かつ正確な算出が期待される。しかし、AI は通常、モデル内や出力結果の説明が難しい。そこで、各特徴量が予測結果にどの程度影響を与えるかを評価可能な SHAP 値を用いて、所要調整力算出のために重要な特徴量を選定し、予測値とその分散を算出可能なガウス過程回帰を用いて、XAI である ORM-XGPR を提案した。系統解析で得られた所要調整力と気象庁 MSM データを用いて、学習することで、気象解析と系統解析を統合することができ、SHAP 値を用いた解析を行うことで、AI の解釈可能性と説明可能性が向上した。また、ORM-XGPR (①) または ORM-XGPR (①・③) を適用することで、運用日に応じて学習期間がマッチすれば、リスク低減および燃料費削減効果が確認された。さらに、PV 主力化が進むと、リスクが収束し、燃料費が削減できる可能性も示唆された。一方、運用日と学習期間が時間的に遠ければ、平均的な所要調整力を予測することも分かった。

一方で、今回の新たな取り組みでは、精度向上や説明可能かどうかの妥当性には課題が残る。そのため、所要調整力以外の系統データを入力に含めた解析が今後必要となる。それにより、モデルや予測手法が複雑になることから、より一層、出力の解釈可能性と説明可能性、その妥当性の評価が重要となる。

## 文 献

- (1) B. Mohandes, M. S. E. Moursi, N. Hatziaargyriou, and S. E. Khatib: "A Review of Power System Flexibility with High Penetration of Renewables", *IEEE Transactions on Power Systems*, Vol. 34, No. 4, pp. 3140-3155 (2019)
- (2) Australian Energy Market Operator: "Black System South Australia 28 September 2016", (2016)
- (3) Z. Movahedian, and A. Askarzadeh: "Multi-objective optimization framework of a photovoltaic-diesel generator hybrid energy system considering operating reserve", *Sustainable Cities and Society*, Vol. 41, pp. 1-12 (2018)
- (4) E. F. Alves, L. Polleux, G. Guerassimoff, M. Korpas, and E. Tedeschi: "Allocation of Spinning Reserves in Autonomous Grids Considering Frequency Stability Constraints and Short-Term Solar Power Variations", *IEEE Access*, Vol. 11, pp. 29896-29908 (2023)
- (5) N. Costilla-Enriquez, M. Ortega-Vazquez, A. Tuohy, A. Motley, and R. Webb: "Operating Dynamic Reserve Dimensioning Using Probabilistic Forecasts", *IEEE Transactions on Power Systems*, Vol. 38, No. 1, pp. 603-616 (2023)
- (6) Y. Chen: "Addressing Uncertainties Through Improved Reserve Product Design", *IEEE Transactions on Power Systems*, Vol. 38, No. 4, pp. 3911-3923 (2023)
- (7) K. Knorr, A. Dreher, and D. Böttger: "Common dimensioning of frequency restoration reserve capacities for European load-frequency control blocks: An advanced dynamic probabilistic approach", *Electric Power Systems Research*, Vol. 170, pp. 358-363 (2018)

- (8) Z. Zhen, J. Liu, Z. Zhang, F. Wang, H. Chai, Y. Yu, X. Lu, T. Wang, and Y. Lin: "Deep Learning Based Surface Irradiance Mapping Model for Solar PV Power Forecasting Using Sky Image", *IEEE Transactions on Industry Applications*, Vol. 56, No. 4, pp. 3385-3396 (2020)
- (9) F. Wang, Z. Xuan, Z. Zhen, K. Li, T. Wang, and M. Shi: "A day-ahead PV power forecasting method based on LSTM-RNN model and time correlation modification under partial daily pattern prediction framework", *Energy Conversion and Management*, Vol. 212, pp. 112766 (2019)
- (10) H. Sharadga, S. Hajimirza, and R. S. Balog: "Time series forecasting of solar power generation for large-scale photovoltaic plants", *Renewable Energy*, Vol. 150, pp. 797-807 (2020)
- (11) J. Wang, Y. Zhou, and Z. Li: "Hour-ahead photovoltaic generation forecasting method based on machine learning and multi-objective optimization algorithm", *Applied Energy*, Vol. 312, pp. 118725 (2022)
- (12) H. Zang, L. Cheng, T. Ding, K. W. Cheung, Z. Wei, and G. Sun: "Day-ahead photovoltaic power forecasting approach based on deep convolutional neural networks and meta-learning", *International Journal of Electrical Power and Energy Systems*, Vol. 118, pp. 105790 (2020)
- (13) C. S. Lai, C. Zhong, K. Pan, W. W. Y. Ng, and L. L. Lai: "A deep learning based hybrid method for hourly solar radiation forecasting", *Expert Systems with Applications*, Vol. 177, pp. 114941 (2021)
- (14) M. Pierro, M. De Felice, E. Maggioni, D. Moser, A. Perotto, F. Spada, and C. Cornaro: "Residual load probabilistic forecast for reserve assessment: A real case study", *Renewable Energy*, Vol. 149, pp. 508-522 (2020)
- (15) Y. Okuyama, and R. Matsuhashi: "Stochastic unit commitment taking exchange of power and reserve through tie lines into consideration", *IEEE Transactions on Power and Energy*, Vol. 141, No. 3, pp. 233-246 (2021) (in Japanese)
- 奥山雄太・松橋隆治:「連系線による電力及び調整力の融通を考慮した確率的起動停止計画」, 電学論 B, Vol. 141, No. 3, pp. 233-246 (2021)
- (16) D. L. Woodruff, J. Deride, A. Staid, J. P. Watson, G. Slevogt, and C. Silva-Monroy: "Constructing probabilistic scenarios for wide-area solar power generation", *Solar Energy*, Vol. 160, pp. 153-167 (2018)
- (17) S. Theodorides, G. Makrides, A. Livera, M. Theristis, P. Kaimakis, and G. E. Georgiou: "Day-ahead photovoltaic power production forecasting methodology based on machine learning and statistical post-processing", *Applied Energy*, Vol. 268, pp. 115023 (2020)
- (18) X. Liu, Y. Liu, X. Kong, L. Ma, A. H. Besheer, and K. Y. Lee: "Deep neural network for forecasting of photovoltaic power based on wavelet packet decomposition with similar day analysis", *Energy*, Vol. 271, pp. 126963 (2023)
- (19) G. Li, X. Wei, and H. Yang: "Decomposition integration and error correction method for photovoltaic power forecasting", *Measurement: Journal of the International Measurement Confederation*, Vol. 208, pp. 112462 (2023)
- (20) Q. Shao, S. Liu, Y. Xie, X. Zhu, Y. Zhang, J. Wang, and J. Tang: "Probabilistic Forecasting of Available Load Supply Capacity for Renewable-Energy-Based Power Systems", *Applied Sciences*, Vol. 13, No. 15, pp. 8860 (2023).
- (21) H. Zhou, J. Wang, F. Ouyang, C. Cui, and X. Li: "A Two-Stage method for Ultra-Short-Term PV Power Forecasting based on Data-Driven", *IEEE Access*, Vol. 11, pp. 41175-41189 (2023)
- (22) R. Liu, J. Wei, G. Sun, S. M. Mueen, S. Lin, and F. Li: "A short-term probabilistic photovoltaic power prediction method based on feature selection and improved LSTM neural network", *Electric Power Systems Research*, Vol. 210, pp. 108069 (2022)
- (23) P. Liu, S. Han, and N. Rong: "Frequency stability prediction of renewable energy penetrated power systems using CoAtNet and SHAP values", *Engineering Applications of Artificial Intelligence*, Vol. 123, pp. 106403 (2023)
- (24) K. Zhang, J. Zhang, P. D. Xu, T. Gao, and D. W. Gao: "Explainable AI in Deep Reinforcement Learning Models for Power System Emergency Control", *IEEE Transactions on Computational Social Systems*, Vol. 9, No. 2, pp. 419-427 (2022)
- (25) J. Kruse, B. Schäfer, and D. Witthaut: "Revealing drivers and risks for power grid frequency stability with explainable AI", *Patterns*, Vol. 2, No. 11, pp. 100365 (2021)
- (26) J. Kruse, B. Schäfer, and D. Witthaut: "Secondary control activation analysed and predicted with explainable AI", *Electric Power Systems Research*, Vol. 170, pp. 358-363 (2018)



Research, Vol. 212, pp. 108489 (2022)

- (27) 電力広域的運営推進機関:「下げ $\Delta$ kW(下げ調整力)の調達について」, 第43回需給調整市場検討小委員会 第54回調整力の細分化及び広域調達の技術的検討に関する作業会, 資料 3 (2023) (閲覧日: 2023年12月8日)
- (28) National Institute of Standards and Technology: “Artificial Intelligence Risk Management Framework (AI RMF 1.0)” (January 2021)
- (29) Investigating R&D Committee on recommended practice for simulation models for automatic generation control: “Recommended practice for simulation models for automatic generation control”, Technical Report of Electrical Engineers of Japan, Vol. 1386 (2016) (in Japanese)  
電力需給解析モデル標準化調査専門委員会:「電力需給・周波数シミュレーションの標準解析モデル」, 電気学会技術報告 第1386号 (2016)
- (30) 北陸電力送配電株式会社:「再エネ出力制御の実施状況について」, 第46回総合資源エネルギー調査会 省エネルギー・新エネルギー分科会 新エネルギー小委員会/電力・ガス事業分科会電力・ガス基本政策小委員会 系統ワーキンググループ, 資料 2-2 (2023) (閲覧日: 2023年12月8日)

西田 啓人



(学生員) 2023年3月福井大学大学院工学研究科博士前期課程修了。同年4月同研究科博士後期課程入学, 現在に至る。主として, 電力系統の計画・運用, 太陽光発電システムに関する研究に従事。エネルギー・資源学会, IEEE, CIGRE 会員。

重信 颯人



(正員) 2015年3月琉球大学工学部電気電子工学科卒業。2017年4月日本学術振興会特別研究員(DC1)を経て, 2019年3月同大学院理工学研究科博士後期課程修了。同年4月福井大学学術研究院工学系部門助教, 2023年4月同部門講師, 現在に至る。博士(工学)。主として, 電力系統解析, 配電系統, 太陽光発電システム, 最適化理論に関する研究に従事。

IEEE, CIGRE 会員。

高橋 明子



(正員) 2012年3月熊本大学大学院自然科学研究科博士後期課程修了。同年6月岡山大学大学院自然科学研究科助教, 2020年10月同研究科准教授, 2023年10月福井大学学術研究院基盤部門特命准教授, 現在に至る。博士(工学)。主として, 太陽光発電システムにおける電力平滑化制御, 画像解析を用いた日射量推定・予測, 太陽光発電導入時の配電系統における電圧制御に関する研究に従事。

伊藤 雅一



(上級会員) 2006年3月東京農工大学大学院工学研究科博士後期課程修了。在学中日本学術振興会特別研究員(DC1)。同年4月東京工業大学特任助教。2012年日本学術振興会海外特別研究員(フランス原子力代替エネルギー庁/国立太陽エネルギー研究所)。2014年6月早稲田大学研究院准教授, 2019年3月福井大学学術研究院工学系部門准教授, 2024年4月より同教授, 現在に至る。博士(工学)。主として, 太陽光発電システム, 電力系統, LCA に関する研究に従事。日本太陽エネルギー学会, エネルギー・資源学会, 電気設備学会, 日本太陽光発電学会会員。

田岡 久雄



(フェロー) 1977年3月東京大学工学部電気工学科卒業。1979年3月同大学大学院工学系研究科修士課程修了。同年4月三菱電機(株)入社。2003年4月福井工業大学教授。2010年4月福井大学大学院工学研究科電気・電子工学専攻准教授, 2012年4月より同教授。2020年4月より大和大学理工学部教授。博士(工学)。主として, 電力システムの解析・制御・運用に関する研究に従事。1985年5月電気学会電気学術振興賞論文賞, 1995年11月電気科学技術奨励賞オーム技術賞受賞。2019年11月澁澤賞受賞, 2020年8月電気保安功労者経済産業大臣表彰, IEEE Fellow, CIGRE 特別会員, 電気設備学会会員, 計測自動制御学会会員。

金尾 則一



(上級会員) 1984年3月名古屋大学大学院工学研究科博士前期課程修了。同年4月北陸電力(株)入社, 2006年3月福井大学大学院工学研究科博士後期課程単位取得退学。2024年9月定年退職。博士(工学)。主として, 電力系統解析に関する研究開発に従事。

杉本 仁志



(正員) 1988年3月新潟大学工学部電気工学科卒業。同年4月北陸電力(株)入社。主として, 配電設備の絶縁設計, 雷害防止対策に関する研究に従事。博士(工学)。2023年7月北陸計器工業に転籍。電気設備学会会員。